

深度强化学习中的时序信用分配：问题定义与典型方法

概述

这篇综述讨论的核心问题是：智能体得到一个结果后，怎样判断过去哪些动作真正促成了这个结果。论文没有提出一种新的信用分配算法，而是统一定义了信用分配问题，并从 MDP 的深度、密度和广度三个维度解释现有方法为什么会失败，随后梳理了基于时间邻近性和回报分解的两类代表性方法。

论文链接：[A Survey of Temporal Credit Assignment in Deep Reinforcement Learning](#)

1. 信用分配问题是什么

强化学习通常只告诉智能体最终获得了多少奖励，却不会直接说明奖励应该归因于哪个动作。

例如，在“拿钥匙—开门—到达终点”的任务中，智能体可能先拿到钥匙，随后执行很多无关动作，最后打开门并得到奖励。真正关键的是很早之前“拿钥匙”的动作，但它和奖励之间隔了很长时间。如果算法只是强化奖励出现前的几个动作，就可能把信用错误地分给那些无关动作。

这就是时序信用分配问题：学习过去动作和未来结果之间的联系。

论文进一步指出，信用分配不能简单理解成“把奖励平均分给过去的动作”。更准确地说，它是在学习一个动作影响函数：

$$K(c, a, g),$$

其中 c 表示动作发生时的上下文， a 是动作， g 是需要评价的目标。 $K(c, a, g)$ 表示动作 a 在上下文 c 中对目标 g 有多大影响。

实际算法无法直接获得真实的 K ，只能利用有限经验 D ，训练一个参数化函数：

$$\widetilde{K}(c, a, g; \phi) \approx K(c, a, g).$$

因此，论文将信用分配问题形式化为：

如何利用有限经验，学习一个能够准确估计动作影响力的函数。

这里存在一个基本矛盾：越接近真实因果关系的影响力度量，通常越难从有限经验中学习； Q 值等统计量比较容易学习，但它们反映的主要是相关性，不一定是真正的因果贡献。

2. 价值学习为什么与信用分配有关

在 MDP 中，从时刻 t 开始的回报为：

$$Z_t = \sum_{k=t}^T \gamma^{k-t} R(S_k, A_k).$$

状态价值函数和动作价值函数分别为：

$$V^{\pi}(s) = \mathbb{E}[Z_t \mid S_t = s],$$

$$Q^{\pi}(s, a) = \mathbb{E}[Z_t \mid S_t = s, A_t = a].$$

Q 值把未来可能获得的回报压缩成当前动作的一个数值，因此经常被当作动作影响力的代理。广义策略迭代会交替进行：

1. 策略评估：估计当前策略的 V 或 Q ；
2. 策略改进：选择价值更高的动作。

因此，如果价值函数错误地把高价值赋给了无关动作，策略也会沿着错误方向更新。信用分配的质量最终会影响训练速度、样本效率和策略质量。

不过，Q 值并不等于严格意义上的信用。它回答的是“采取这个动作后预计能获得多少回报”，而不是“这个动作究竟在多大程度上导致了该结果”。

3. 信用分配的三类困难

论文用 MDP 的深度、密度和广度整理了信用分配中的主要困难。

3.1 MDP 深度：动作与结果相隔太远

MDP 深度表示重要动作与结果之间隔了多少个时间步。深度越大，信用就需要沿着更长的时间链向前传播。

中间还可能夹杂大量无关动作，使算法容易把信用分给时间上接近奖励、但并没有真正促成奖励的动作。这对应延迟奖励和长期信用分配问题。

3.2 MDP 密度：真正有影响的动作太少

MDP 密度反映动作与目标之间有效关联的丰富程度。

当环境随机性很强，或者只有极少数状态和动作序列能够产生奖励时，大多数动作几乎不改变结果。智能体很少得到有信息量的学习信号，也就没有足够的信用可以向前传播。

这通常表现为稀疏奖励问题。

3.3 MDP 广度：到达同一结果的路径太多

MDP 广度表示有多少条不同路径可以产生相同结果。

如果很多动作序列都能到达目标，就不存在唯一的關鍵路径，信用会被分散到大量可能路径中。智能体只找到一条成功轨迹时，可能错误地认为这条轨迹中的动作都非常重要，却不知道其他动作组合也能获得相同结果。

论文将这种现象称为信用稀释。

3.4 信用分配与探索的区别

探索负责发现成功轨迹，信用分配负责理解成功轨迹。

在钥匙—门任务中，探索让智能体偶然发现“拿钥匙—开门—到达终点”的序列；信用分配则负责学到“拿钥匙是后来开门的必要条件”，从而在以后主动重复这一行为。

如果智能体从未发现奖励，主要问题可能是探索；如果已经见过成功轨迹，却仍然学不会重复关键动作，问题更可能出在信用分配上。实际训练中两者经常互相影响，因此很难完全分开。

4. 基于时间邻近性的信用分配

第 6.1 节介绍的方法共享一个基本假设：

动作在时间上离结果越近，对结果的影响就越大。

这是一种简单而有效的启发式规则，但时间先后和真正的因果关系并不是一回事。

4.1 TD 学习

TD 学习使用下面的 TD 误差更新价值函数：

$$\delta_t = r_t + \gamma Q^\pi(s_{t+1}, a_{t+1}) - Q^\pi(s_t, a_t).$$

如果实际观察到的“即时奖励加下一状态价值”高于当前估计，说明当前状态—动作对被低估；反之则说明它被高估。

TD 并不是把最终奖励显式拆成若干份，而是利用 TD 误差不断调整状态—动作对的价值。通过反复自举，奖励信息可以从后面的状态逐步传播到前面的状态。

它的问题也很直接：奖励信息通常只能逐步向前传递。任务很长时，早期关键动作需要经过很多轮更新才能得到正确价值，而且中间动作也可能因为靠近奖励而被错误强化。

4.2 基于优势函数的方法

优势函数定义为：

$$A^\pi(s, a) = Q^\pi(s, a) - V^\pi(s).$$

它衡量的不是动作能够获得多少绝对回报，而是：

在当前状态下，动作 a 比策略平均会采取的动作好多少。

Actor-Critic 使用 $V^\pi(s)$ 作为基线，可以在不改变策略梯度期望的情况下减小方差。优势函数也更适合比较同一状态下的不同动作。

Dueling DQN 把 Q 值分解为状态价值和动作优势：

$$Q(s, a) = V(s) + \left(A(s, a) - \frac{1}{|\mathcal{A}|} \sum_{a'} A(s, a') \right).$$

这样可以分别学习“这个状态总体上好不好”和“某个动作相对其他动作好不好”。

在完全可观测 MDP 中，优势还可以近似写成动作的因果效应：

$$\mathbb{E}[Z \mid s, a] - \mathbb{E}[Z \mid s].$$

但这仍不是真正完整的因果估计，因为 Q 值和 V 值都受到后续策略、环境随机性等因素影响。

4.3 资格迹

资格迹为过去访问过的状态—动作对维护一个随时间衰减的权重：

$$e_t(s, a).$$

当状态—动作对被访问时，它的资格迹上升；之后随时间逐渐衰减。当前产生 TD 误差时，不只更新当前动作，还按照资格迹更新过去的动作：

$$\Delta Q(s, a) \propto \delta_t e_t(s, a).$$

因此，资格迹实际分配的是：

当前 TD 误差应当以多大权重更新过去的状态—动作对。

距离当前时间越近的动作通常具有越大的迹，因此获得更强的更新。经典 TD (λ) 就使用资格迹实现多步信用传播，它位于单步 TD 和蒙特卡洛回报之间。

资格迹能够比单步 TD 更快地向过去传播信息，但它仍然依赖时间邻近性。一个动作即使没有真正影响结果，只要它最近被访问过，也可能获得较高权重。

ETD 在此基础上引入强调迹和兴趣函数，重新调整不同状态更新的重要程度，主要用于缓解离策略学习与函数逼近结合时的不稳定问题。

4.4 Options 与 Option-Critic

另一种思路是把多个原子动作组合成一个时间上延展的宏动作，即 option 或 skill。

例如，可以把“移动到钥匙旁并捡起钥匙”看成一个 option，而不是分别评价其中每一步移动。这样，一条数百步的动作序列可能被压缩成：

拿钥匙→开门→到达终点.拿钥匙→开门→到达终点.

信用传播的有效时间跨度因此变短。

Option-Critic 同时学习：

- option 内部应该执行哪些原子动作；
- 什么时候终止当前 option；
- 当前状态应该选择哪个 option。

所以它包含两层信用分配：

1. 将子目标的信用分配给 option 内部动作；
2. 将最终任务的信用分配给不同 options。

这种方法适合具有明显层次结构的长任务，但如果子目标或 option 划分不合理，问题本身并不会自动消失。

5. 回报分解方法

第 6.2 节尝试回答一个更直接的问题：

最终回报中的多少部分应该归因于每个时间步？

这类方法把终止时得到的回报重新分配到轨迹中的关键位置，构造更清晰、更及时的学习信号。

5.1 TVT：通过记忆传输价值

Temporal Value Transport 使用外部长时记忆保存过去的重要事件。

当智能体在当前时刻获得重要结果时，模型会从记忆中读取与当前结果相关的过去状态—动作对，并把当前价值直接传输回这些遥远事件。

因此，TVT 中的信用主要由记忆检索关系决定：

- 某个过去事件越容易在预测当前结果时被检索出来；
- 就认为它对当前结果越重要。

这种方法可以绕过很长的时间距离，但记忆检索到的是相关性，不一定是严格因果关系。

5.2 RUDDER：用回报预测差分重新分配奖励

RUDDER 先使用 LSTM 根据整条状态—动作序列预测最终回报。假设模型在看到某个关键动作后，对最终回报的预测突然上升，那么这次预测变化就说明该动作提供了重要信息。

它把相邻时间步的回报预测差定义为重新分配后的奖励：

$$r_t^* = f(s_{t+1}, a_{t+1}) - f(s_t, a_t).$$

相比普通 TD，这种方法能够更直接地处理长时间延迟。但它依赖回报预测模型是否准确，而且目前缺少一般性的理论保证，不能证明重新分配一定比 TD 更正确。

5.3 SECRET：把注意力权重作为信用

SECRET 使用因果 Transformer，根据观察和动作序列预测奖励序列。

模型预测某个奖励时，会对过去不同状态—动作对分配注意力权重。SECRET 将这些注意力权重解释为过去动作对奖励的贡献：

- 注意力越高，分配的信用越多；
- 注意力越低，分配的信用越少。

它的优点是能够直接建立长距离关联，而且在任务分布上训练后可以迁移到新任务。

但需要注意，注意力权重只能说明模型在预测时使用了哪些信息，不能自动证明这些信息在因果上造成了奖励。因此，“attention is credit”更像一种有效启发式，而不是严格结论。

5.4 SR：学习合成奖励

Synthetic Returns 假设终止奖励主要由一个早期关键事件造成。

它把较早出现、能够预示后续奖励的状态称为 operant，把后来真正产生奖励的状态称为 reinforcer。模型通过情景记忆学习两者之间的关联，然后在再次观察到 operant 时直接产生合成奖励。

例如，模型学会“拿到钥匙通常预示之后能够得到终点奖励”，那么以后拿到钥匙时就立即产生一个合成奖励，而不必等待最终奖励逐步传播回来。

该方法能够绕过局部 TD 更新，但限制比较明显：

- 假设主要只有一个动作应当获得信用；
- 对超参数较敏感；
- 面对多个动作共同促成结果的任务时不够自然。

6. 这些方法汇总

方法	实际分配或学习的对象
TD	用 TD 误差更新当前状态—动作价值
优势方法	动作相对于当前状态平均行为的额外价值
资格迹 / $TD(\lambda)$	当前 TD 误差对过去状态—动作对的更新权重
Options	子目标信用在原子动作和宏动作之间的层次化分配
TVT	当前价值与过去记忆事件之间的检索关联
RUDDER	最终回报在各个时间步上的重新分配奖励
SECRET	预测奖励时，模型对过去状态—动作对的注意力权重
SR	从终止奖励反推得到的早期合成奖励

其中，只有 RUDDER、SECRET、SR 等方法比较接近“把一个最终回报拆成每一步的贡献”。TD 和资格迹做的主要是价值更新与误差传播，并没有显式回答“最终奖励中有多少属于这个动作”。

7. 总结与理解

这篇综述最有价值的地方，是把一个比较模糊的问题转换成了统一的函数学习问题：从有限经验中估计动作对结果的影响。

第 6.1 节的方法主要依赖时间结构。TD 使用自举逐步传播奖励，资格迹一次更新多个过去动作，优势函数评价动作相对于平均行为的额外价值，options 则通过时间抽象缩短信用传播距离。这些方法容易与现有 RL 算法结合，但共同的问题是容易把时间邻近性误认为因果关系。

第 6.2 节的方法更主动地寻找长距离关联。TVT 使用记忆检索，RUDDER 根据回报预测变化重新分配奖励，SECRET 使用注意力权重，SR 学习合成奖励。它们在延迟奖励任务上通常比普通 TD 更有效，但检索分数、预测差分和注意力权重仍然只是动作影响力的近似，并不等于严格的因果信用。

因此，信用分配并不存在一种对所有任务都最合适的方法。延迟不严重时，TD 和 $TD(\lambda)$ 已经足够有效；任务具有明显层次结构时，可以使用 options；最终奖励延迟很长时，回报分解和记忆方法更有优势。而对于奖励极度稀疏或存在大量替代路径的任务，仅靠这些方法仍然不够，还需要目标条件化、事后重标记、反事实推理或反向规划等方法。